

# 一文看懂logistic回归为什么要用sigmoid函数

楼主有这样的疑问非常的正常，让我慢慢来解释你的问题。

## 一、第一个问题：为什么要用 sigmoid 函数？从两个角度解答

### 1.1 第一个角度

首先要明确的一点是：不是因为 sigmoid 有很多优秀的性质，然后在 logistic 回归模型建立的时候，从而使用 sigmoid 函数，这样是不合理的，因为在数学当中 sigmoid 是一个函数族。具备 sigmoid 函数这样的性质的函数有很多。

在解释之前需要了解的知识： A:指数族分布 B: 广义线性模型

#### A: 指数族分布

指数族分布满足下面的公式，即：

$$p(y;\eta) = b(y)\exp(\eta T(y) - a(\eta))$$

$\eta$  为自然参数， $T(y)$  为充分统计量，通常  $T(y) = y$ ,  $a(\eta)$  为正则化项。

#### B: 广义线性模型

满足下面三个假设的模型称为广义线性模型

- ①  $y|x; \theta$  满足一个以  $\eta$  为参数的指数族分布
- ② 给定  $x$ ，我们目标是预测  $y$  的期望值，即  $h(x) = E(y|x)$
- ③  $\eta = \theta^T x$

首先在二分类中，我们假设  $y$  服从贝努利分布，贝努利分布为指数族分布，因为

$$\begin{aligned} p(y|\theta) &= \phi^y (1-\phi)^{1-y} \\ &= \exp(y \log \phi + (1-y) \log(1-\phi)) \\ &= \exp\left(\log \frac{\phi}{1-\phi} y + \log(1-\phi)\right) \end{aligned}$$

我们令

$$\begin{cases} \eta = \log\left(\frac{\phi}{1-\phi}\right) \Rightarrow \phi = \frac{1}{1+e^{-\eta}} \\ a(\eta) = -\log(1-\phi) = \log(1+e^{\eta}) \\ b(y) = 1 \end{cases}$$

所以可以得出贝努利分布属于指数族分布。

即贝努利分布满足广义线性模型的第一个假设，下面利用广义线性模型后面两个假设得

19645269

到:

$$h_{\theta}(x) = E(y|x;\theta) = \phi = \frac{1}{1+e^{-z}} = \frac{1}{1+e^{-\theta^T x}}$$

从而得到我们的预测目标即 sigmoid 函数, 用来作为后验概率  $p(y=1|x)$

## 1.2 第二个角度

在解释第二个角度, 我是假设楼主是比较了解贝叶斯判别。在贝叶斯判别中, 理论得出了机器学习模型的精度上界, 即最大化后验概率。而 logistic 回归中也是通过 sigmoid 函数来逼近后验概率  $p(y=1|x)$ 。通过贝叶斯公式得出

$$p(y=1|x) = \frac{p(x|y=1)p(y=1)}{p(x|y=0)p(y=0) + p(x|y=1)p(y=1)}$$

在这里我们假设先验服从贝努利分布, 类条件概率服从高斯分布即

$$\begin{cases} p(y=1) = \phi \\ p(y=0) = 1-\phi \\ p(x|y=1) = \frac{1}{(2\pi l)^{d/2} |\Sigma|^{1/2}} \exp(-(x-u_1)^T \Sigma^{-1} (x-u_1)) \end{cases}$$

将上式带入  $p(y=1|x)$  即

$$\begin{aligned} p(y=1|x) &= \frac{p(x|y=1)p(y=1)}{p(x|y=0)p(y=0) + p(x|y=1)p(y=1)} \\ &= \frac{1}{1 + \frac{p(x|y=0)p(y=0)}{p(x|y=1)p(y=1)}} \\ &= \frac{1}{1 + \frac{1-\phi}{\phi} \exp((u_0-u_1)^T \Sigma^{-1} x + \frac{1}{2}(u_1^T \Sigma^{-1} u_1 - u_0^T \Sigma^{-1} u_0))} \\ &= \frac{1}{1 + \exp((u_0-u_1)^T \Sigma^{-1} x + \frac{1}{2}(u_1^T \Sigma^{-1} u_1 - u_0^T \Sigma^{-1} u_0) + \ln(\frac{1-\phi}{\phi}))} \end{aligned}$$

令,  $-w_0 = \frac{1}{2}(u_1^T \Sigma^{-1} u_1 - u_0^T \Sigma^{-1} u_0) + \ln(\frac{1-\phi}{\phi})$ ,  $-w = \Sigma^{-1}(u_0 - u_1)$  的可以得出

激活 Windows

转到“设置”以激活 Windows


[//blog.csdn.net/qq\\_19645200](https://blog.csdn.net/qq_19645200)

$$p(y=1|x) = \frac{1}{1+e^{-(w^T x + w_0)}}$$

不局限于类条件概率服从高斯分布，只要类条件概率服从指数族分布，都可以推出后验概率为 sigmoid 函数的形式。从而可以看出 logistic 回归的强大的鲁棒性。

## 二、第二个问题：为什么可以做成概率呢？

就是因为 sigmoid 函数这样优秀的性质，将输入变量的范围从  $(-\infty, +\infty)$ ，映射到  $(0, 1)$ ，而概率要求的正数范围在  $(0, 1)$  之间，所以可以作为后验概率的形式。最后在配个 sigmoid 函数漂亮的曲线。



[//blog.csdn.net/qq\\_19645269](http://blog.csdn.net/qq_19645269)